MODUL M114: DATENKOMPRESSION — CHEAT SHEET (DL07 - DL09)

A5-Kompaktspickzettel · Formeln, Beispiele, Algorithmen & Prüfungsfallen

DL07: FORMELN, BERECHNUNGEN & GRUNDLAGEN

Exakte Formeln (G_alt = Original, G_neu = Komprimiert):

Kompressionsfaktor K: K = G_alt / G_neu (einheitenlos, K > 1)
Restgrösse R (%): R = (G_neu / G_alt) × 100%
Einsparung E (%): E = ((G_alt - G_neu) / G_alt) × 100% = 100% - R
Gegenprobe: R + E = 100% (Prüfungskontrolle!)

Schritt-für-Schritt Rechenbeispiel:

Gegeben: G_alt = 120 KB, G_neu = 30 KB

- **K** = 120 / 30 = **4.0** (Datei ist 4x kleiner)
- **R** = (30 / 120) × 100% = **25%** (25% Restdaten)
- **E** = 100% - 25% = **75%** (75% Speicher eingespart)

Kernkonzepte DL07:

- **Redundanz:** Überflüssige Info (wiederholte Bitmuster).
- **Verlustfrei:** 100% Rekonstruktion (Text, ZIP, PNG, FLAC).
- **Verlustbehaftet:** Irrelevante Info verworfen (JPEG, MP3).
- **Expansion:** G_neu > G_alt (E < 0%, K < 1). Tritt auf wenn z.B. bereits komprimierte Dateien (JPEG/MP3) in ZIP gepackt werden.

DL08: RLE & HUFFMAN-KODIERUNG

Run-Length Encoding (RLE):

- **Prinzip:** Ersetzt Folgen gleicher Zeichen durch (Anzahl, Zeichen).
- **Codierung:** WWWWWWBBBWW → 6W3B2W (11 → 6 Zeichen).
- **RLE-Falle:** Bei unregelmässigen Daten (ABCDEF → 1A1B1C1D1E1F) verdoppelt RLE die Dateigrösse!

Huffman-Kodierung (Entropiekodierung):

- **Prinzip:** Häufige Zeichen erhalten kurze Bitcodes, seltene lange.
- **Präfixfrei:** Kein Code ist Anfang eines anderen Codes! Eindeutig decodierbar ohne Trennzeichen.
- **Baumaufbau:** 1. Häufigkeiten zählen. 2. Die 2 kleinsten Knoten zusammenfassen. 3. Äste mit 0 (links) / 1 (rechts) beschriften.

Huffman-Beispiel: "EEEEETTAN"

1. Häufigkeit (9 Zeichen): E:5, T:2, A:1, N:1
2. Bitcodes: E="0" (1b), T="10" (2b), A="110" (3b), N="111" (3b)
3. Bitmenge neu: (5×1) + (2×2) + (1×3) + (1×3) = **15 Bits!**
4. Vergleich: Fixed 2-Bit = 18b | ASCII 8-Bit = 72 Bits.
   => **K_ASCII = 4.8** (72/15) | **E_ASCII = 79.2%**

DL08: LZW WÖRTERBUCH-ALGORITHMUS

LZW (Lempel-Ziv-Welch) Wörterbuchverfahren:

- **Prinzip:** Ersetzt wiederkehrende Strings dynamisch durch Wörterbuch-Indizes.
- **WICHTIG:** Wörterbuch wird NICHT mitgesendet! Empfänger baut es beim Decodieren synchron auf.

Beispiel-Codierung für Eingabe "ABABABA":

Liest	Ausgabe	Neu ins WB	Index
Start	A=1, B=2	(Initial-WB)	1, 2
AB	1 (A)	AB	3
BA	2 (B)	BA	4
ABA	3 (AB)	ABA	5
Rest	5 (ABA)	-	-

Ergebnis: Ausgabestrom: [1, 2, 3, 5] (7 Zeichen auf 4 Indizes komprimiert)

DL09: BILD- UND AUDIOKOMPRESSION

Bildformate im Vergleich (Praxislabor):

- **BMP:** Unkomprimiert, 24-Bit RGB (Pixel × 3 Bytes). Sehr grosse Dateien!
- **PNG:** Verlustfrei (RLE/Deflate), unterstützt Alphakanal (Transparenz). Ideal für Grafik, Text, Logos, Screenshots.
- **JPEG:** Verlustbehaftet (DCT, Farbraum YCbCr 4:2:0, Quantisierung). Ideal für Fotos. Q90 = kaum Verlust, Q30 = Blockartefakte.
- **Faire Beurteilung:** Nur bei 1:1 Zoom (100%), gleicher Pixelauflösung und Fokus auf detailreiche Kanten aussagekräftig!

Audioformate & Bitratenrechnung:

- **WAV (PCM):** Unkomprimiertes Rohaudio. Bitrate (Bit/s) = Abtastrate (Hz) × Bit-Tiefe × Kanäle.
  CD-Qualität: 44.100 Hz × 16 Bit × 2 (Stereo) = 1.411,2 kbit/s
  Speicher/Min: (1.411.200 × 60) / 8 / 1024 / 1024 = **10,09 MB/Min!**
- **FLAC:** Verlustfrei komprimiert (spart ~40-50% Daten gegenüber WAV).
- **MP3:** Verlustbehaftet (Psychoakustik: verdeckt unhörbare Töne & Hörschwellen). 192 kbit/s spart ~86% Daten. 64 kbit/s wirkt dumpf (Artefakte).

EINHEITEN & ZEITRECHNUNG

Einheiten, Umrechnungen & Datenraten:

- **Grundlage:** 1 Byte (B) = 8 Bits (b). Bitrate in bit/s, Dateigrösse in Byte (B).
- **Dezimal (SI):** 1 KB = 1.000 B | 1 MB = 1.000 KB = 1.000.000 B
- **Binär (IEC):** 1 KiB = 1.024 B | 1 MiB = 1.024 KiB = 1.048.576 B

Formel Übertragungszeit:

Gleichung: t (s) = Dateigrösse (Bits) / Bitrate (bit/s)
Rechenbeispiel: Gegeben: 20 MB Datei über 32 Mbit/s Anschluss
1. In Bits umrechnen: 20 MB × 8 = 160 Megabit (Mbit)
2. Zeit berechnen: t = 160 Mbit / 32 Mbit/s = **5,0 Sekunden**

PRÜFUNGS-MERKSÄTZE & STOLPERFALLEN

Wichtige Prüfungs-Knacknüsse (M114):

- **Einheiten-Falle:** Faktor K hat KEINE Einheit! Restgrösse R & Einsparung E sind immer Prozentwerte (%).
- **ZIP-Mythen:** ZIP macht Dateien NICHT automatisch verschlüsselt/sicher & stellt KEINE bereits gelöschten Infos wieder her!
- **RLE-Grenze:** RLE lohnt sich NUR bei langen gleichen Zeichenfolgen (z.B. Fax/Strichgrafik). Bei Zufallstext verdoppelt RLE die Daten!
- **Huffman-Präfix:** Huffman-Codes müssen PRÄFIXFREI sein (kein Code ist Anfang eines anderen) -> ermöglicht eindeutiges Decodieren ohne Trennzeichen.
- **LZW-Übertragung:** LZW-Wörterbuch wird NIE mitgesendet! Sender & Empfänger starten beide synchron mit ASCII (0-255).
- **Verlust-Kumulation:** Mehrfaches Speichern verlustbehafteter Formate (z.B. JPEG -> JPEG neu) verschlechtert die Qualität kumulativ & irreversibel!
- **Psychoakustik:** MP3 nutzt Hörschwellen & Frequenzmaskierung des menschlichen Gehörs aus (Entfernen von unhörbaren Tönen).
- **Redundanz vs. Irrelevanz:** Redundanz = Info-Dopplung (verlustfrei entfernbar). Irrelevanz = Für Empfänger unwichtige Info (verlustbehaftet verworfen).