MODUL M114: DATENKOMPRESSION — CHEAT SHEET (DL07 - DL09)

Einseitige A5-Spickübersicht · Formeln, RLE, Huffman, LZW, ZIP, Bild & Audio

1. DL07: GRUNDLAGEN DER KOMPRESSION

- **Ziel & Zweck:** Reduktion von Speicherplatz & Übertragungszeit [1, 30].
- **Redundanz:** Ausnutzen von Wiederholungen/Mustern in Daten [2, 40].
- **Verlustfrei:** Bytes bleiben nach Entpacken 100% exakt erhalten (ZIP, PNG, FLAC, RLE, Huffman, LZW) [2, 24].
- **Verlustbehaftet:** Irreversible Entnahme von Infos für hohe Kompression; Original nicht exakt wiederherstellbar (JPEG, MP3) [2, 24].

Formeln & Kennzahlen (DL07.5):

Grösse Vorher: D_{vor}	**Grösse Nachher:** D_{nach} (in Bytes)
Faktor K: D_{vor} / D_{nach} (einheitenlos)	**Restgrösse R:** (D_{nach} / D_{vor}) × 100%
Einsparung E: 100% − R = (1 − D_{nach}/D_{vor}) × 100%	**Kontrolle: $R + E$ = 100%**

- **Expansion (E < 0%):** Wenn $D_{nach} > D_{vor}$ (z.B. Metadaten bei winzigen Dateien), ist E negativ und R > 100% [3, 28, 33].
- **ZIP-Regeln:** Komprimiert via Deflate (LZW+Huffman) [133]. Komprimiertes (JPEG, MP3) spart via ZIP kaum Platz (E ≈ 0%) [3, 27]. ZIP bringt gelöschte Infos *nicht* zurück [3, 32] & ist *kein* Lese-Schutz (braucht PW/Verschlüsselung) [3, 31]. Nur Byte-Grösse für Rechnungen nutzen [15, 37].
- **Formatwahl:** Python-Code **ZIP** (verlustfrei) [4, 29]; Schulwebseite Foto **JPEG** (klein, verlustbehaftet) [4, 29]; Logo Transparenz **PNG** (scharf, Transparenz) [4, 29].

2. DL08: KOMPRESSIONSVERFAHREN

A) RLE (Lauflängenkodierung):

- **Idee:** Ersetzt direkt benachbarte gleiche Zeichen durch *Anzahl + Zeichen* [4, 58].
- **Regel:** 4B = BBBB [5, 58]. Einzelzeichen erhalten Anzahl (1A) [115].
- **Beispiele:** WWWWWWBBBWW (11) 6W3B2W (6) [60, 88]. AAABCCCCCDD 3A1B6C2D [61, 89].
- **Expansion:** ABCDEFGH (8) 1A1B1C1D1E1F1G1H (16) [63, 91]. ABABAB (6) 1A1B1A1B1A1B (12) [35, 63, 91].
- **Grenze:** Hilft NUR bei direkt aufeinanderfolgenden gleichen Zeichen [5, 35]!

B) Huffman-Codierung:

- **Idee:** Häufige Zeichen erhalten kurze Bitcodes, seltene lange Codes [65, 77].
- **Präfixfrei:** Kein Code ist Anfang eines anderen Codes Bitstrom ohne Trennzeichen eindeutig decodierbar [67, 94, 119].
- **Baumaufbau:** 1. Häufigkeiten zählen 2. Die 2 kleinsten freien Knoten verbinden 3. Wiederholen bis Wurzel 4. Äste beschriften (links=0, rechts=1) & ablesen [5, 68, 69, 97].

Zchn	Häuf.	Code	Bits Tot.
E	5	0 (1 Bit)	5 × 1 = 5
T	2	10 (2 Bits)	2 × 2 = 4
A	1	110 (3 Bits)	1 × 3 = 3
N	1	111 (3 Bits)	1 × 3 = 3
Tot.	9	**Huffman: 15 Bit**	Fix (2Bit): 18 Bit

Bsp. EEEEETTAN: 15 Bit statt 18 Bit (2 Bit/Zchn) Ersparnis: 3 Bits [98-99, 122].

C) LZW-Verfahren (Lempel-Ziv-Welch):

- **Idee:** Ersetzt wiederkehrende Zeichenketten durch Wörterbuchnummern [6, 73].
- **Algorithmus (Start: A=1, B=2):**

1. Längste bekannte Gruppe im Resttext suchen & Code ausgeben [6, 74].
2. Neues Wort (bekannte Gruppe + 1. nächster Buchstabe) eintragen (Codes 3, 4...) [6, 74].
3. Verwendete Gruppe im Resttext streichen [6, 74].

- **Vorteil:** Empfänger baut Wörterbuch beim Decodieren synchron selbst auf muss **nicht mitgesendet werden**! [76, 103, 126]

Schritt	Rest vorher	Bekannt	Ausgabe	Eintrag
1	AB...ABA	**A**	**1**	AB = 3
2	BABABA	**B**	**2**	BA = 4
3	ABABA	**AB**	**3**	ABA = 5
4	ABA	**ABA**	**5**	(Ende)

Ausgabecodes für ABABABA: **1, 2, 3, 5** [76, 103].

Verfahrenswahl nach Datenmuster (DL08.9):

Muster	Verfahren	Grund & Eigenschaft
AAAAAA...	RLE	Direkt benachbarte gleiche Zeichen [77, 105]
Text (viel E, wenig Q)	Huffman	Häufigkeitsbasierte Bitcodes [77, 105]
M114-TEST-M114...	LZW	Wiederkehrende Wortgruppen [77, 105]

3. DL09: BILD- UND AUDIOKOMPRESSION

A) Bildkompression & Dateiformate:

- **BMP:** Unkomprimiert, volle RGB-Pixelwerte, sehr gross [8, 150].
- **PNG:** Verlustfrei, RGB-Pixelwerte bleiben 100% erhalten, Transparenz, ideal für Grafiken/Logos [4, 29, 152].
- **JPEG:** Verlustbehaftet. Qualitätsstufen (z.B. 90 vs 30; keine %-Angaben!). Q=90: hohe Qual.; Q=30: starke Kompression, Blockartefakte/unscharfe Kanten [8, 147, 150]. Ideal für Fotos [4, 29].
- **Fairer Bildvergleich:** Gleiche Pixelmasse (z.B. 2407×3495), gleiche Bildstelle (X,Y) & gleicher Zoom (z.B. 100%) [8, 149].

Format / Stufe	Typ	Rel. Grösse	Merkmal / Qualität
BMP	Unkompr.	100% (25.2 MB)	Original, volle Bytes [150]
PNG	Verlustfrei	~68% (17.1 MB)	Verlustfrei, Transparenz [150]
JPEG (Q=90)	Verlustbeh.	~8.8% (2.2 MB)	Sehr gut, kaum Kantenverl. [150]
JPEG (Q=30)	Verlustbeh.	~2.6% (0.66 MB)	Starke Artefakte / Ränder [150]

B) Audiokompression & Bitraten:

- **WAV:** Unkomprimiertes PCM-Audio (44.1 kHz, 16 Bit, Stereo). *Formel WAV-Grösse:* Dauer (s) × 44'100 × 16 × 2 / 8 = Bytes (~176.4 kB/s) [173].
- **FLAC:** Verlustfrei, behält ALLE PCM-Tonmesswerte 100% bei (~30-40% Ersparnis) Erste Wahl zum Archivieren! [154, 161, 172].
- **MP3:** Verlustbehaftet (Psychoakustik). Bitrate bestimmt Datenmenge/s. *Formel MP3-Grösse:* Dauer (s) × Bitrate (kbit/s) / 8 = kB [173].
  - **192 kbit/s:** Hohe Qualität (kaum Hörunterschied) [9, 159].
  - **64 kbit/s:** 1/3 der Datenmenge von 192kbit/s, aber hörbar dumpfer [9, 159-160].
- **Fairer Hörvergleich:** Derselbe Abschnitt (10–22s), gleiche Lautstärke, gleiche Kopfhörer [9, 158].

PRÜFUNGS-MERKSÄTZE & STOLPERFALLEN:

1. Faktor K hat KEINE Einheit! Restgrösse R & Einsparung E in % [25, 31].
2. Präfixfrei (Huffman): Kein Code ist Anfang eines anderen Codes [67, 94].
3. LZW-Wörterbuch: Muss NICHT mitgesendet werden (synchron aufgebaut) [76, 126].
4. ZIP auf JPEG/MP3: E ≈ 0% [3, 27]. ZIP bringt gelöschte Infos NICHT zurück [3, 32].